FEMFEDORA · ИССЛЕДОВАТЕЛЬСКИЕ МОДЕЛИ

Две модели риска беременности

Преждевременные роды и гипертензивные расстройства беременности. CDC Natality: обучение на 2023, проверка на 2024

Преждевременные роды · 7,0 млн родов

HDP-proxy · 6,8 млн родов

Октябрь 2026

КОРОТКО

Что получилось

ПРЕЖДЕВРЕМЕННЫЕ РОДЫ

Вероятность родов до 32, 34 и 37 недель

0,640
AUROC, роды <37 нед

0,673
AUROC, роды <32 нед

4,8×
верхний дециль против нижнего

CatBoost · 9 признаков анамнеза · тест: 3,51 млн родов 2024

ГИПЕРТЕНЗИВНЫЕ РАССТРОЙСТВА

Гестационная АГ, преэклампсия, эклампсия

0,664
AUROC, любой HDP

+3,9
случая на 1000 против правила

6,3×
верхний дециль против нижнего

CatBoost · 7 полей анамнеза и 3 маски · тест: 3,39 млн родов 2024

Обе модели точно откалиброваны на новом году и умеренно разделяют женщин по риску.

Все метрики — временной тест: модели обучены на 2023 и проверены на всём 2024

ДАННЫЕ И ПРОВЕРКА

Обучение на 2023, проверка на 2024

2023 · обучение, подбор, калибровка → 2024 · итоговый временной тест

Параметр	Преждевременные роды	HDP-proxy
Единица	одноплодное живорождение	то же, без хронической АГ
Записей 2023	3 480 382	3 369 714
Записей 2024 (тест)	3 512 780	3 394 136
Частота исхода 2024	<37 нед 8,8% · <32 нед 1,24%	10,7%
Разработка на 2023	60 / 20 / 20: обучение / валидация / калибровка	5 фолдов, выбор по log loss
Кандидаты	логистика, LightGBM, CatBoost	логистика, сплайны, HistGB, LightGBM, CatBoost

Источник: CDC/NCHS Natality, резидентки США · идентификатора матери нет

ЧАСТЬ 01

Преждевременные роды

8,8%
родов 2024 года — раньше 37 недель

1,24%
раньше 32 недель

CatBoost, 4 класса срока · прогноз на текущем сроке и по неделям

ПРЕЖДЕВРЕМЕННЫЕ РОДЫ · ВХОДЫ МОДЕЛИ

9 признаков, известных до беременности

Признак	Что это	Пропусков
Возраст матери	лет; в прогнозе — на ПДР	0%
ИМТ до беременности	кг/м²	2,3%
Число предыдущих родов	живые и умершие дети	0,35%
Прерывания и потери	прошлые беременности	0,38%
Преждевременные роды в анамнезе	да / нет	0,13%
Хроническая АГ	да / нет	0,13%
Прегестационный диабет	да / нет	0,13%
Кесарево в анамнезе	да / нет	0,13%
Курение до беременности	сигарет в день	0,45%

ВЫХОД МОДЕЛИ

до 32 нед	**1,24%**
32–33 нед	**0,91%**
34–36 нед	**6,61%**
37 нед и позже	**91,24%**

Доли классов в 2024. Риски до 32, 34 и 37 нед согласованы по построению

НЕ ВХОДЯТ

Срок и осложнения текущей беременности, вес ребёнка, вмешательства, раса и образование

Пропуски — доля в 2024 · у каждого поля есть маска пропуска, всего 17 входов

ПРЕЖДЕВРЕМЕННЫЕ РОДЫ · ФАКТОРЫ

Анамнез поднимает риск в 2–3 раза



27%

после преждевременных родов в анамнезе — втрое выше среднего

23% vs 7,5%

с любым из трёх факторов (ПР в анамнезе, хроническая АГ, диабет) и без них; факторы есть у 7,9% женщин

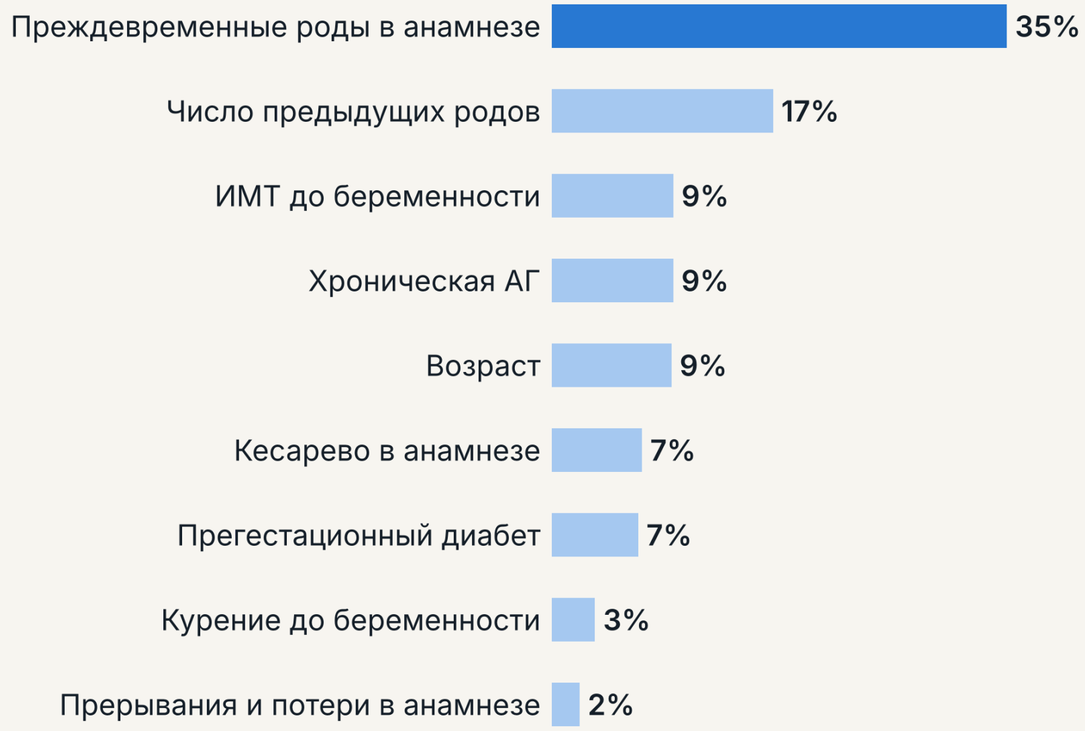
8,8%

у первородящих — как в среднем: без анамнеза модели почти не на что опереться

Доля родов <37 нед, одноплодные живорождения 2024 · описательно, без поправок

ПРЕЖДЕВРЕМЕННЫЕ РОДЫ · ВАЖНОСТЬ ПРИЗНАКОВ

Главное — преждевременные роды в анамнезе



35%

всей важности даёт один вопрос: были ли преждевременные роды

0,640 → 0,593

AUROC <37 нед, если убрать весь акушерский анамнез

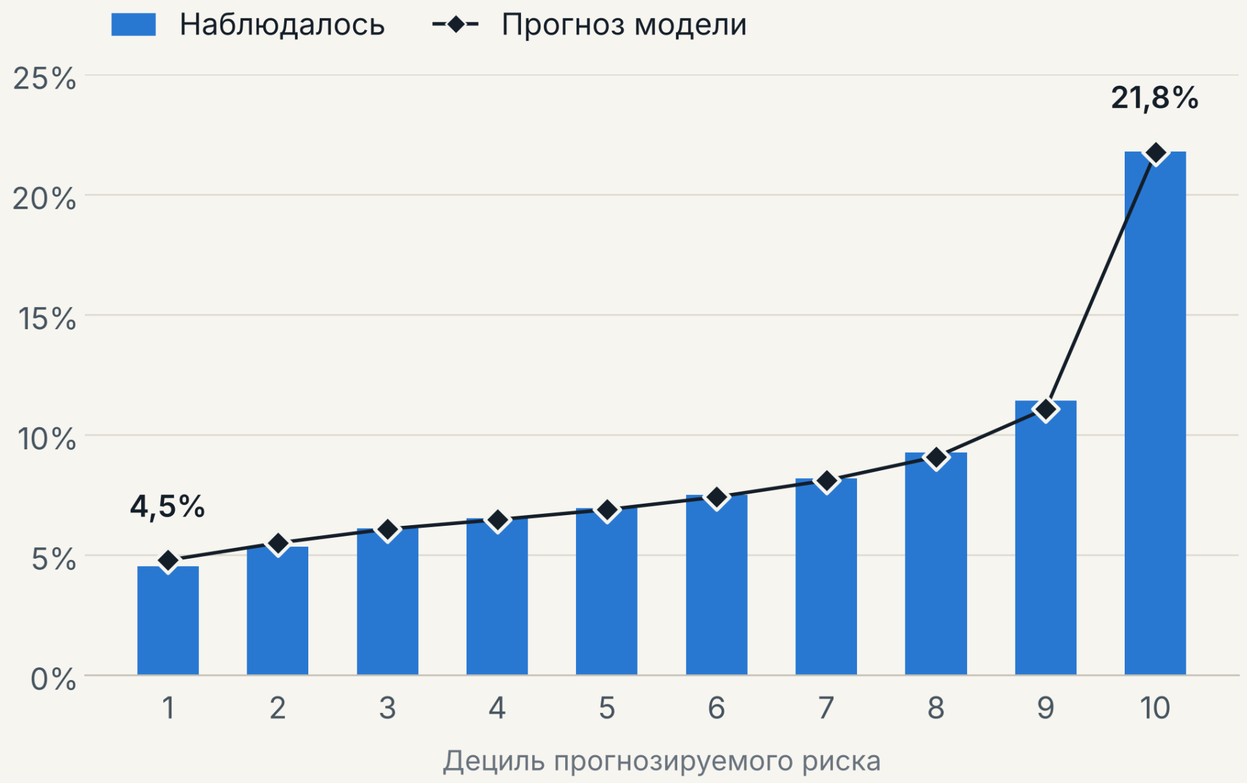
<4%

курение и прошлые прерывания почти не добавляют информации

Перестановочная важность: рост log loss при перемешивании, доля от суммы · полные записи 2023

ПРЕЖДЕВРЕМЕННЫЕ РОДЫ · РАЗДЕЛЕНИЕ РИСКА

Верхний дециль — в 5 раз рискованнее нижнего



4,5 → 21,8%

роды до 37 нед: от 1-го к 10-му децилю прогноза

0,48 → 3,39%

роды до 32 нед: разница в 7 раз

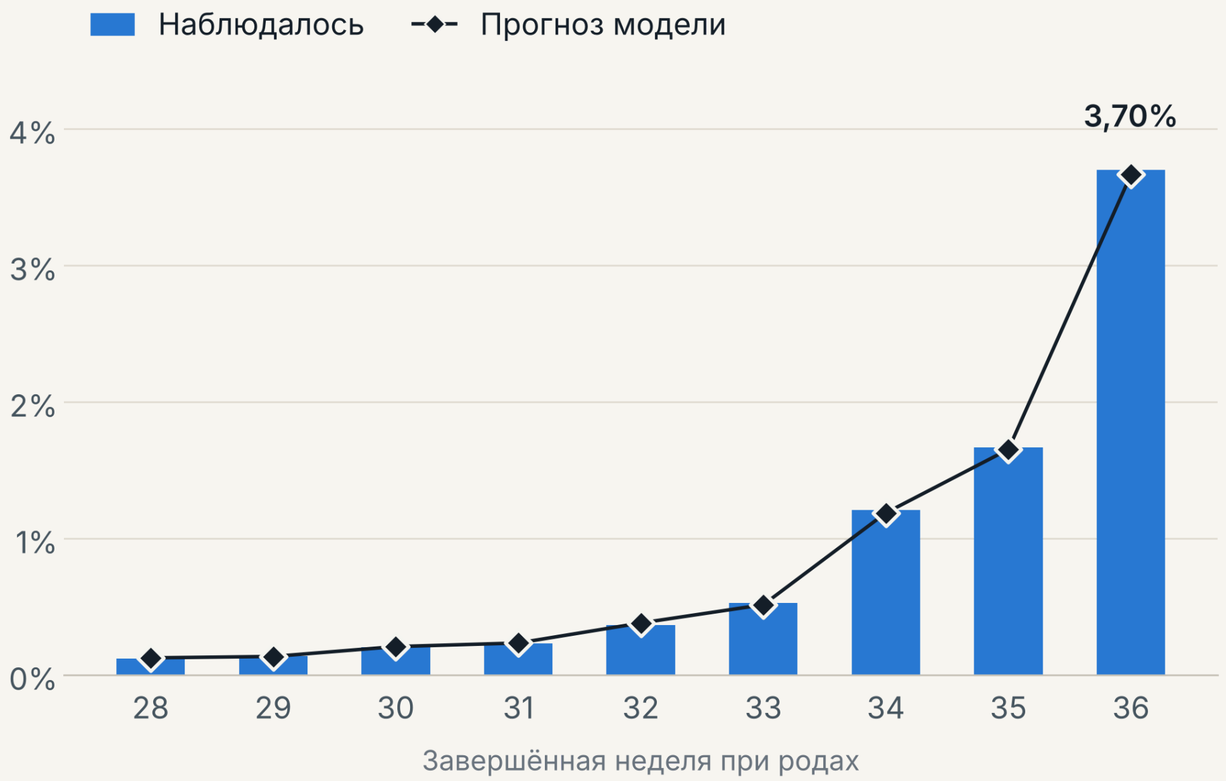
≤0,35 п.п.

максимальное расхождение прогноза и факта по децилям

Все 3 512 780 одноплодных живорождений 2024 · модель видела только 2023

ПРЕЖДЕВРЕМЕННЫЕ РОДЫ · ПРОГНОЗ ПО НЕДЕЛЯМ

Прогноз по неделям совпадает с фактом



8,10 / 8,16%

средний прогноз и фактическая доля родов до 37 нед на сроке 28+0

0,636

AUROC для родов до 37 нед у женщины на 28+0; 0,661 — до 32 нед

0,402

недельный log loss против 0,414 у частотного прогноза

3,38 млн записей 2024 с полностью заполненным анамнезом · доля среди продолжающихся на 28+0

ПРЕЖДЕВРЕМЕННЫЕ РОДЫ · ИТОГОВЫЕ ОЦЕНКИ

Умеренное разделение, точная калибровка

Роды	Частота 2024	AUROC	AUPRC · к частоте	Brier лучше на
до 32 нед	1,24%	0,673	0,032 · 2,5×	0,8%
до 34 нед	2,15%	0,669	0,054 · 2,5×	1,3%
до 37 нед	8,76%	0,640	0,176 · 2,0×	3,5%

−3,8%
log loss против частотного прогноза: 0,347 vs 0,360

0,999
температура калибровки: поправка вероятностям почти не нужна

0,59
AUROC до 37 нед у первородящих — слабое место модели

CatBoost, глубина 5 · 3 512 780 родов 2024 · «к частоте» — во сколько раз AUPRC выше базовой доли

ПРЕЖДЕВРЕМЕННЫЕ РОДЫ · КЛИНИЧЕСКАЯ ЦЕННОСТЬ

Модель против трёх вопросов анамнеза

Правило отмечает женщину, если есть хотя бы одно: преждевременные роды в анамнезе, хроническая АГ, прегестационный диабет. Это 7,8% женщин. Модель отмечает ту же долю с самым высоким риском.

На сроке 28+0	Правило	Модель
Чувствительность, до 37 нед	20,8%	21,2%
PPV, до 37 нед	21,8%	22,3%
Чувствительность, до 32 нед	23,3%	24,4%
PPV, до 32 нед	2,1%	2,2%

0,4–1,1 п.п.

прирост чувствительности: пока модель почти повторяет чек-лист

25% и 27%

всех родов до 37 и до 32 нед попадают в верхние 10% прогноза

Плюс модели

непрерывный риск и разбивка по неделям вместо «да / нет»

3,38 млн записей 2024 с полным анамнезом · одинаковая доля отмеченных — 7,8%

Пример: вымышленная пациентка на 28+3

ВХОДНЫЕ ДАННЫЕ

Срок	**28 нед 3 дня**
Возраст на ПДР	**30 лет**
ИМТ до беременности	**24**
Предыдущие роды	**1, в срок**
АГ, диабет, кесарево	**нет**
Курение	**нет**

Роды до 37 нед

4,3%

в среднем на сроке 8,2%

Роды до 34 нед

0,66%

в среднем 1,6%

Роды до 32 нед

0,26%

в среднем 0,70%

В ближайшие 4 недели

0,33%

плюс распределение по неделям

Незаполненное поле → INSUFFICIENT_DATA: без полного анамнеза модель не выдаёт прогноз

ЧАСТЬ 02

Гипертензивные расстройства беременности

10,7%
родов 2024 года с записанным HDP-proxy

1,9%
HDP и роды раньше 37 недель

Метка объединяет гестационную АГ, преэклампсию и эклампсию: отдельного диагноза ПЭ в CDC нет

HDP-PROXY · ВХОДЫ МОДЕЛИ

7 полей анамнеза и 3 маски пропусков

Признак	Что это	Пропусков
ИМТ до беременности	кг/м² + маска	2,4%
Число предыдущих родов	0 / 1 / 2 / ≥3 + маска	0,34%
Прочие исходы беременностей	прерывания, потери + маска	0,37%
Возраст матери	лет, на дату родов	0%
Прегестационный диабет	да / нет	0%
Преждевременные роды в анамнезе	да / нет	0%
Кесарево в анамнезе	да / нет	0%

МЕТКА

Гестационная АГ, преэклампсия или эклампсия — одним флагом

ИСКЛЮЧЕНЫ

Женщины с хронической АГ: 115 909 записей в 2024

ОТДЕЛЬНЫЕ МОДЕЛИ

ВРТ и демография — только в проверках чувствительности

Пропуски — доля в 2024 · бинарные поля в когорте заполнены полностью

HDP-PROXY · ФАКТОРЫ

Диабет и ожирение — самые сильные факторы



24,7%

при прегестационном диабете — в 2,3 раза выше среднего

13,5% vs 8,8%

первые роды против повторных; первородящих — 40%

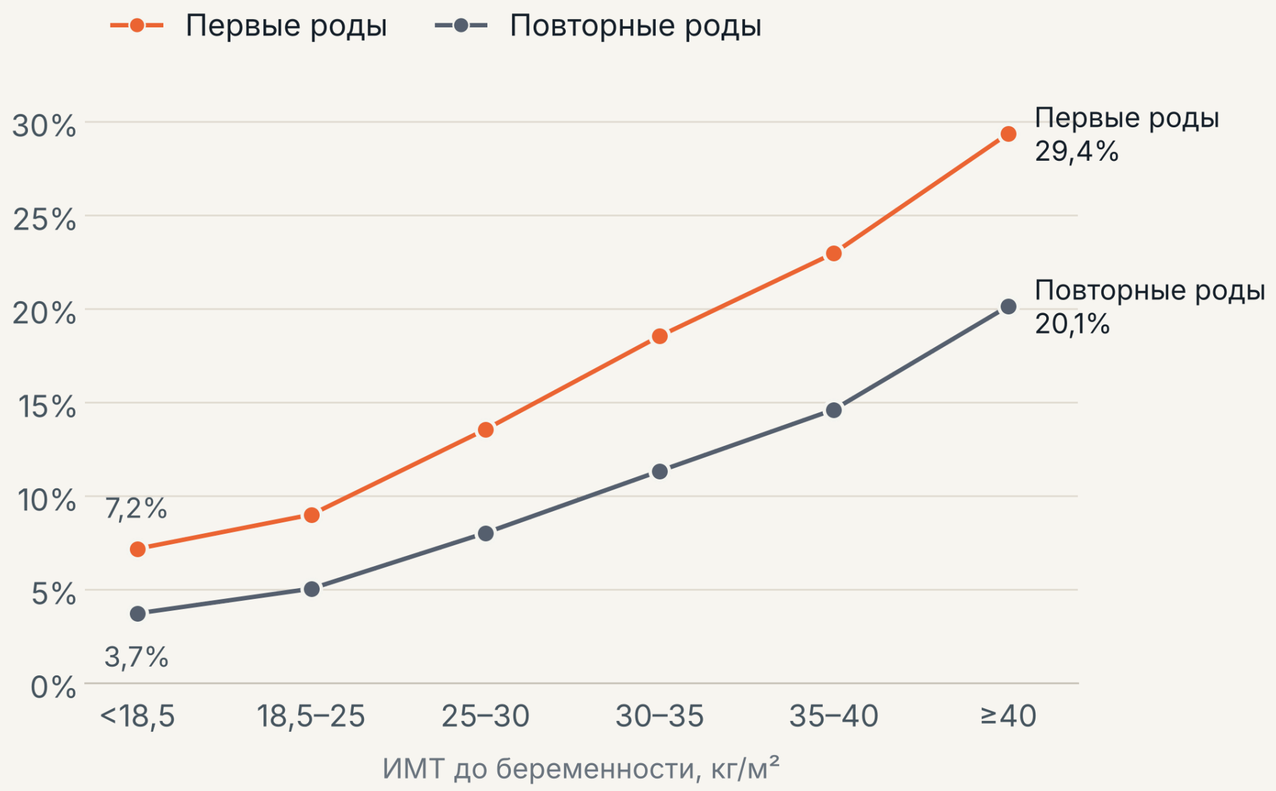
10,0%

кесарево в анамнезе — чуть ниже среднего: эти женщины уже рожали

Доля HDP-proxy, одноплодные живорождения 2024 без хронической АГ · описательно, без поправок

HDP-PROXY · ИМТ И ПАРИТЕТ

С ростом ИМТ частота HDP растёт в 4 раза



29%

первые роды и ИМТ от 40 — почти каждая третья

3,7%

повторные роды и ИМТ ниже 18,5 — разница в 8 раз

+3–9 п.п.

добавляют первые роды на каждом уровне ИМТ

Фактическая доля HDP-proxy, 3,30 млн родов 2024 с известными ИМТ и паритетом

HDP-PROXY · ВАЖНОСТЬ ПРИЗНАКОВ

ИМТ даёт почти 60% всей важности



59% + 25%

ИМТ и число предыдущих родов вместе — 84% важности

≤5%

каждый из остальных: возраст, ПР в анамнезе, диабет, кесарево

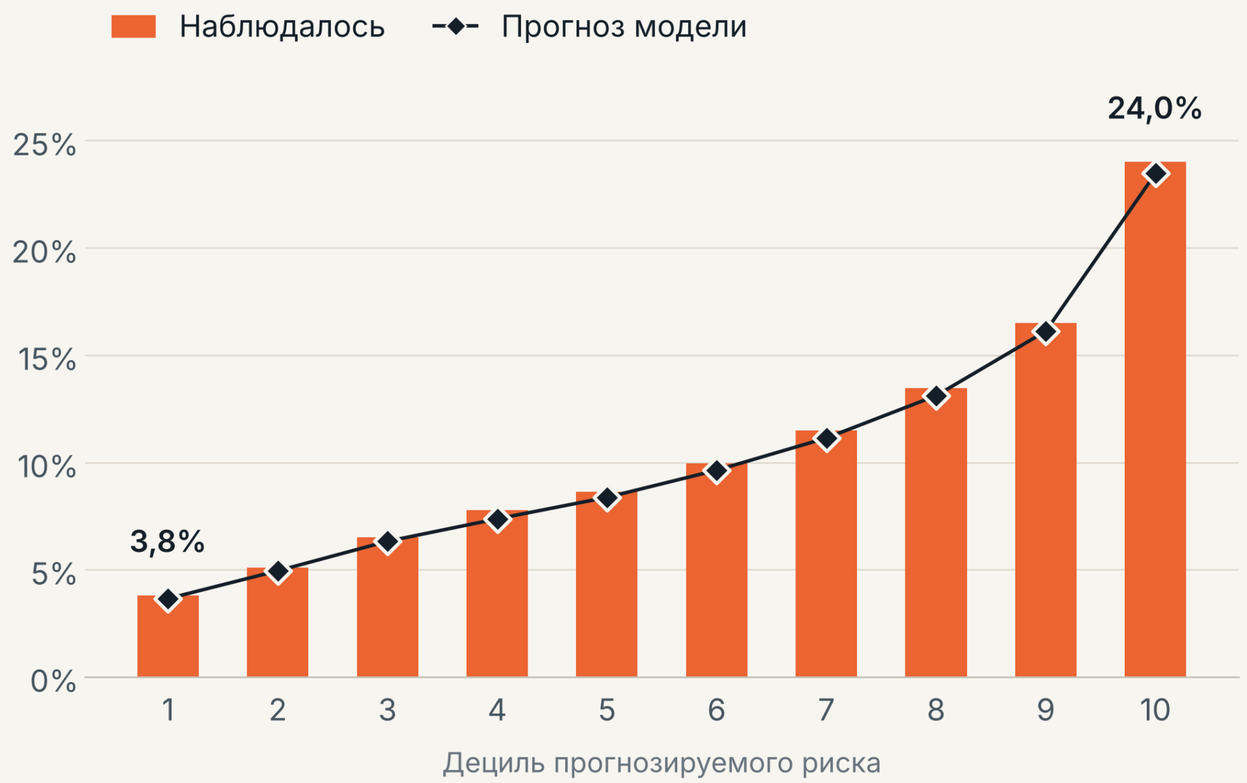
Маски не помогают

модель без масок пропусков даёт тот же AUROC 0,664

Отложенная перестановочная важность CatBoost: падение AUPRC, доля от суммы · 5 фолдов × 3

HDP-PROXY · РАЗДЕЛЕНИЕ РИСКА

Верхний дециль — в 6 раз рискованнее нижнего



3,8 → 24,0%
частота HDP от 1-го к 10-му децилю прогноза

22%
всех случаев HDP — в верхних 10% прогноза

10,4 / 10,7%
средний прогноз и факт: частота в 2024 выросла, модель отстаёт на 0,3 п.п.

CatBoost, обучен на 2023 · все 3 394 136 родов 2024

HDP-PROXY · ИТОГОВЫЕ ОЦЕНКИ

Все алгоритмы упираются в один потолок

Модель · тест 2024	AUROC	AUPRC	Brier	Наклон
Частота, без признаков	0,500	0,107	0,0957	—
Логистическая регрессия	0,656	0,191	0,0926	0,99
Логистика со сплайнами	0,662	0,194	0,0923	0,99
HistGradientBoosting	0,664	0,195	0,0922	1,00
CatBoost	0,664	0,196	0,0922	0,99
LightGBM	0,664	0,195	0,0922	0,99

0,665

AUROC в 5 фолдах 2023+2024 — разброс в третьем знаке

0,706

AUROC для тяжёлого фенотипа: HDP и роды до 34 нед

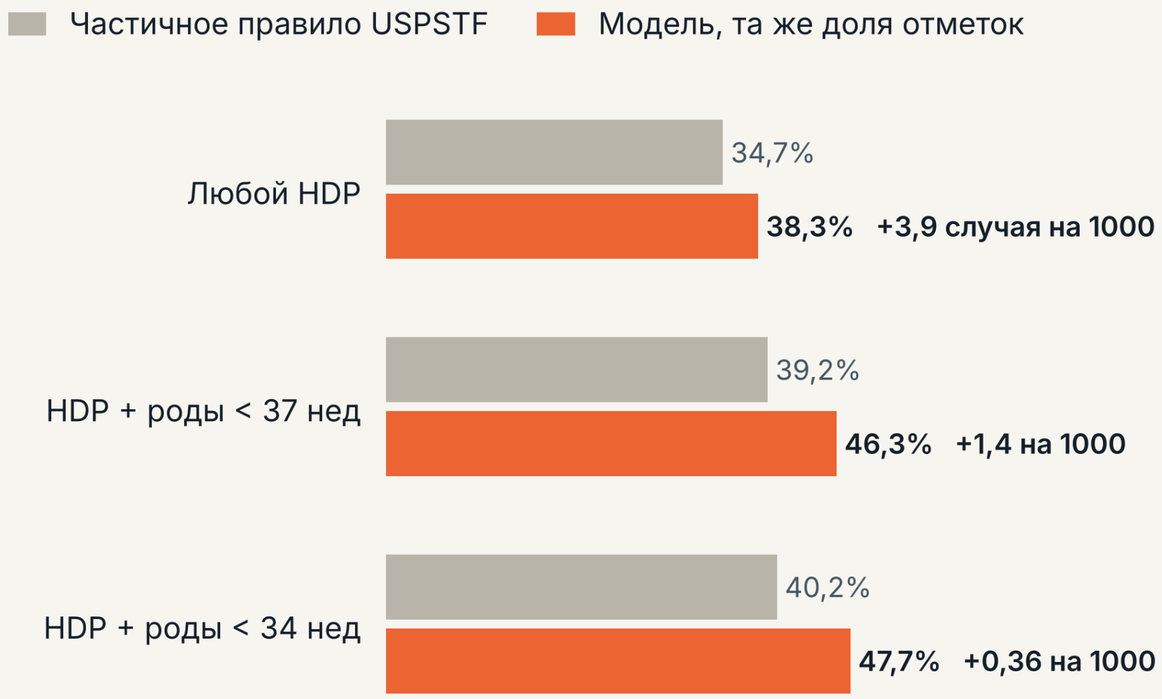
+0,009

AUROC от расы и образования — ниже порога 0,01, не включены

3 394 136 родов 2024 · наклон — калибровочный наклон, идеал 1,00

HDP-PROXY · КЛИНИЧЕСКАЯ ЦЕННОСТЬ

Модель находит больше случаев, чем правило



+3,9

случая HDP на 1000 женщин при той же нагрузке: 41,0 против 37,1

+7 п.п.

чувствительности для тяжёлых, преждевременных форм

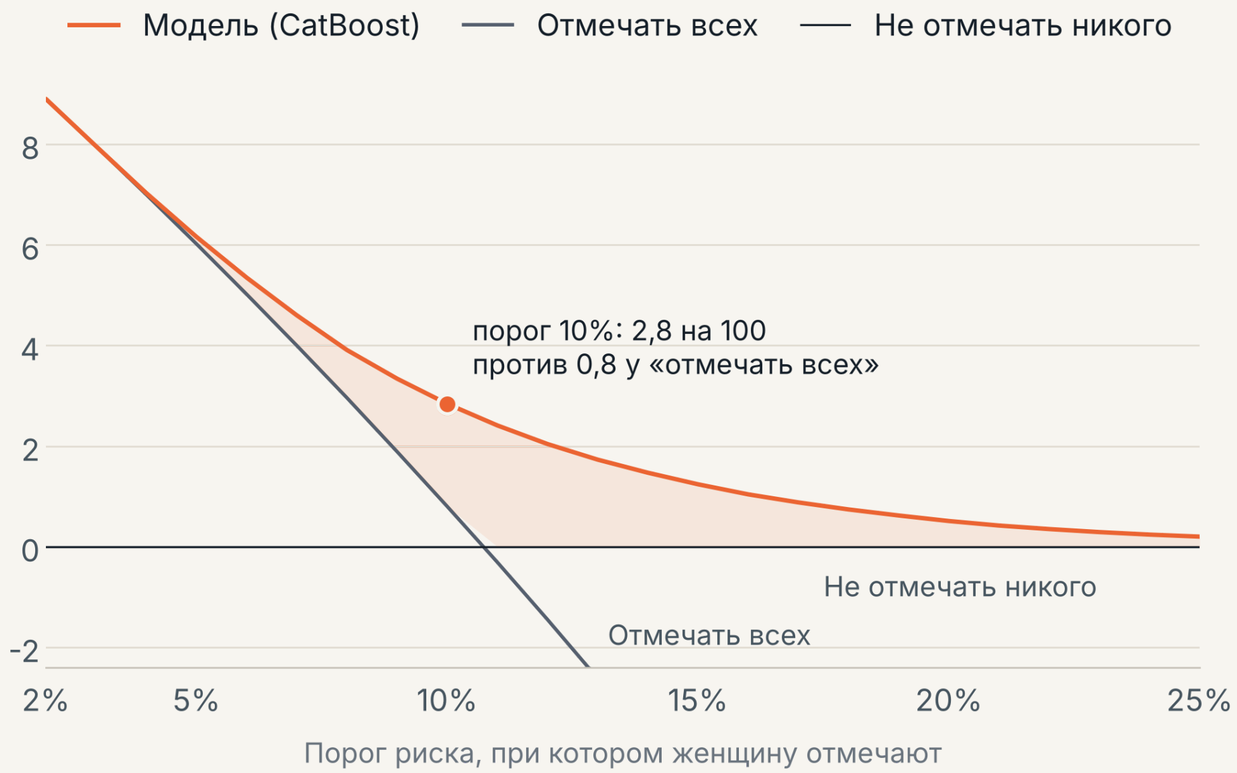
Правило — частичное

диабет или 2 из 3: возраст ≥35, ИМТ ≥30, первые роды. Прежней ПЭ, почек и семейного анамнеза в CDC нет

2024 · 3,35 млн записей · отмечено 20,3% в обоих вариантах · модель HistGB

HDP-PROXY · ЧИСТАЯ ПОЛЬЗА

Польза выше альтернатив при порогах 5–25%



2,8 vs 0,8

чистая польза на 100 женщин при пороге 10%: модель и «отмечать всех»

42% → 7%

доля отмеченных женщин при пороге 10% и 20%

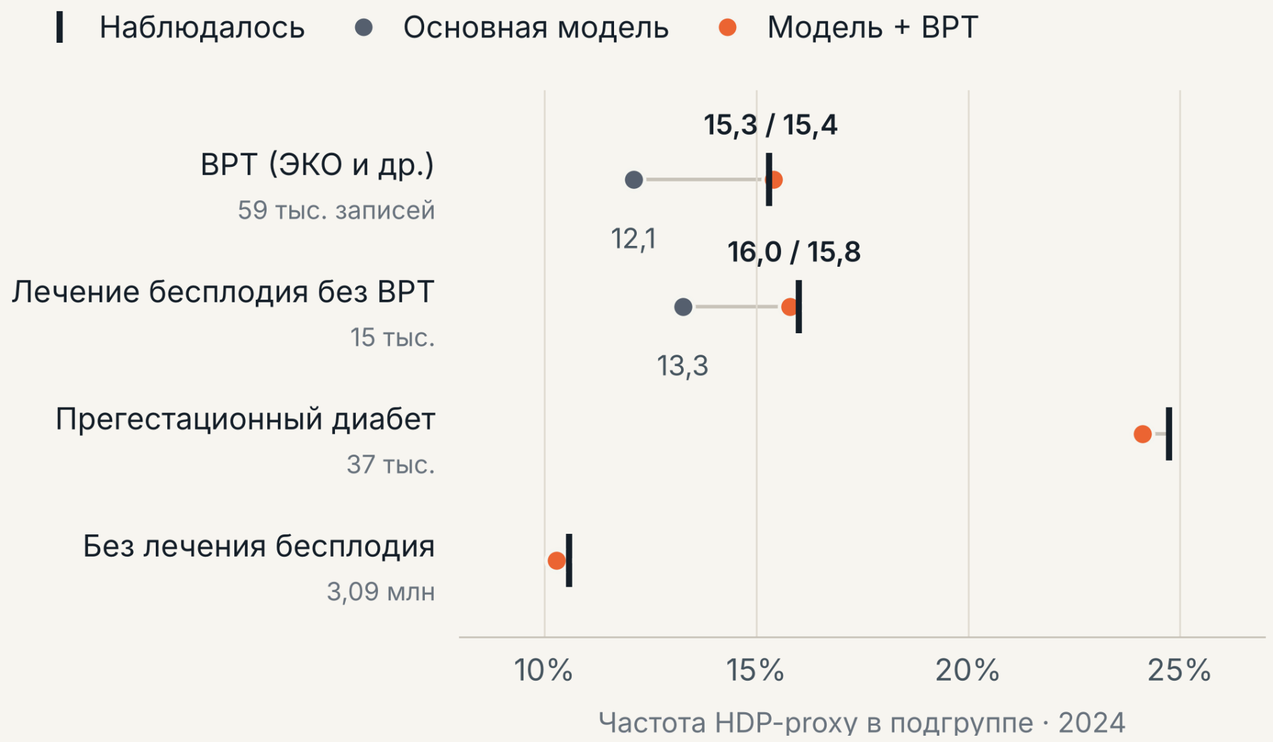
Не про аспирин

кривая описывает записанную метку; данных о профилактике в CDC нет

Decision curve, CatBoost, 2024 · ось Y — чистая польза, случаев на 100 женщин

HDP-PROXY · ПОДГРУППЫ

После ВРТ основная модель занижает риск



Частота HDP-proxy в подгруппе · 2024

12,1 vs 15,3%
прогноз основной модели и факт у женщин после ВРТ

15,4%
прогноз модели с полями ВРТ — занижение исчезает

6,8%
записей 2024 без отчётности по ВРТ — для них работает основная модель

HistGB, тест 2024 · модель с ВРТ использует сведения о лечении бесплодия, доступные после зачатия

СВОДКА

Две модели рядом

Тест 2024	Преждевременные роды	HDP-proxy
Исход	срок родов: до 32 / 34 / 37 нед	гестационная АГ, ПЭ, эклампсия
Главный признак	ПР в анамнезе · 35% важности	ИМТ · 59% важности
Модель	CatBoost, 4 класса срока	CatBoost ≈ LightGBM ≈ HistGB
AUROC	0,640 до 37 · 0,673 до 32 нед	0,664 · 0,706 с родами до 34 нед
Калибровка	температура 0,999	наклон 0,99, занижение 0,3 п.п.
10-й / 1-й дециль	21,8% / 4,5%	24,0% / 3,8%
Против простого правила	+0,4 п.п. чувствительности	+3,6 п.п. · +3,9 случая на 1000

Правила: для ПР — 3 вопроса анамнеза; для HDP — наблюдаемая часть USPSTF

ЧТО ДАЛЬШЕ

Границы результатов и следующие шаги

Ограничения

- Только живорождения США: нет мертворождений, ID матери и дат визитов
- ПР: самопроизвольные и индуцированные роды в одной метке
- HDP: гестационная АГ и ПЭ вместе, нет данных об аспирине
- Пропуск в CDC сам связан с риском — нужна полная анкета
- 2024 уже просматривался: тест временной, но не слепой

Следующие шаги

- Разделить спонтанные и индуцированные преждевременные роды
- Индекс риска на первом визите, в окне профилактики
- Вторая ступень для ПР: цервикометрия и маркеры
- Локальная проверка и перекалибровка на данных РФ
- Порог внедрения: выигрыш над чек-листом и decision curve